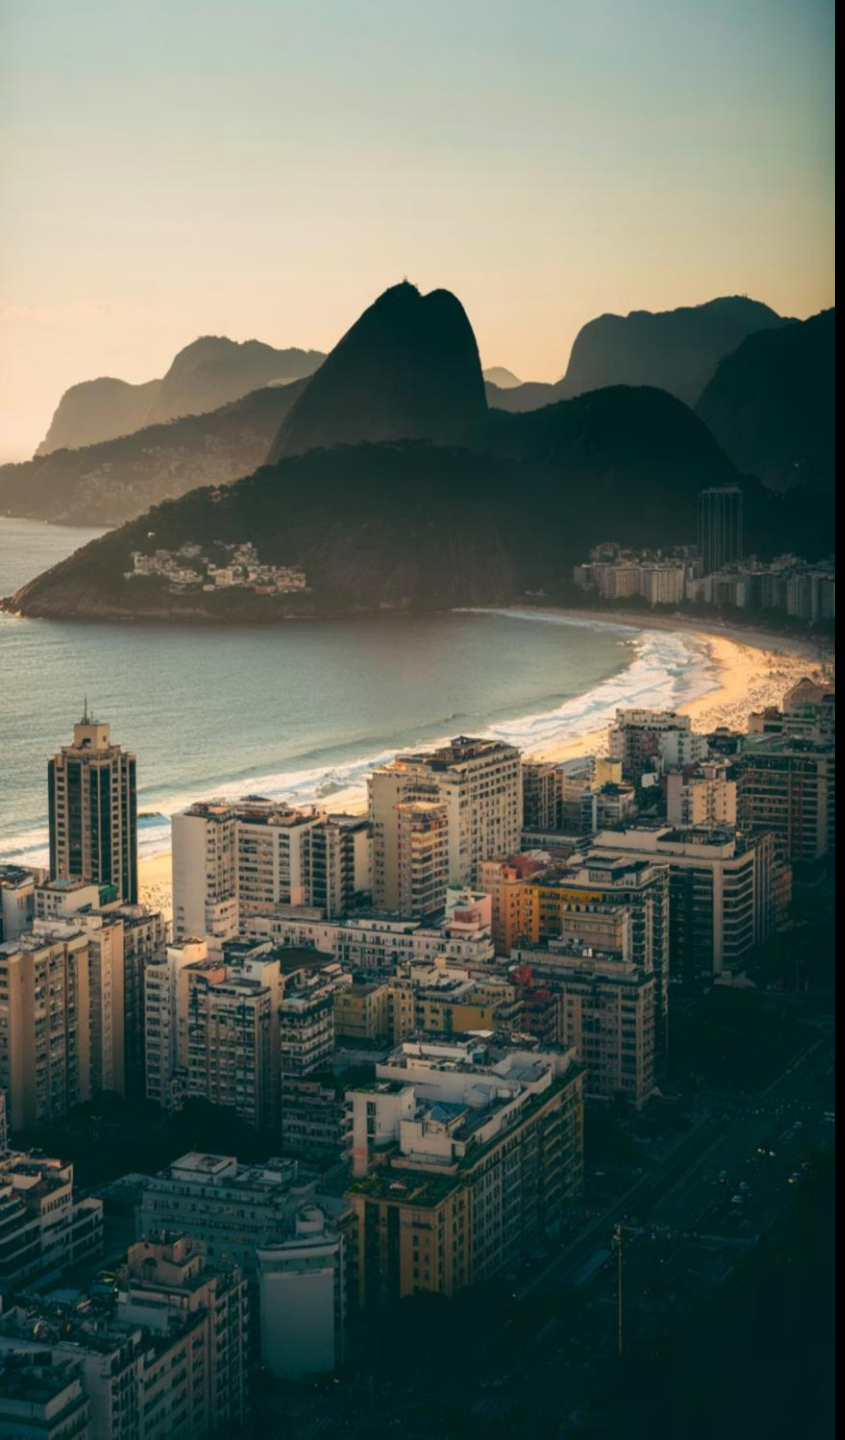

# Análise Exploratória de Dados do Airbnb

*Como o preço e a demanda se comportam no Rio de Janeiro*

Kaiky S. Lima

RA: 2864568

# Objetivo

- Analisar quais fatores influenciam o preço e a demanda dos anúncios do Airbnb no Rio de Janeiro.

- Pergunta:
  O que impacta o valor das diárias e a procura pelos imóveis?

# Base de dados

- Principais variáveis:
- - Preço
- - Tipo de acomodação
- - Bairro
- - Número de reviews (proxy de demanda)
- - Amenidades

```python
import pandas as pd

df = pd.read_csv("listings.csv")

df.head()
```

[619] ✓ 1.4s

| | id | listing_url | scrape_id | last_scraped | source | name | description | neighborhood_overview |
|---|---|---|---|---|---|---|---|---|
| 0 | 821198084644106078 | https://www.airbnb.com/rooms/821198084644106078 | 20250926170004 | 2025-09-27 | city scrape | Bright and Peaceful Leblon Loft | Welcome! Come relax in our bright and stylish ... | Beautiful tree lined street just 3 blocks from... |
| 1 | 821198370698658112 | https://www.airbnb.com/rooms/821198370698658112 | 20250926170004 | 2025-09-27 | city scrape | Copacabana 100% reformado. | Guarantee of a safe and quality stay! <br /><... | Copacabana, in the part near the neighborhood ... |
| 2 | 821200521820144734 | https://www.airbnb.com/rooms/821200521820144734 | 20250926170004 | 2025-09-26 | city scrape | hambiente familia | Relax with the whole family in this quiet acco... | NaN |
| 3 | 821213014263313420 | https://www.airbnb.com/rooms/821213014263313420 | 20250926170004 | 2025-09-27 | previous scrape | Amazing en suite bedroom Leblon | Kick back and relax in this calm, stylish spac... | NaN |
| 4 | 821223043903573522 | https://www.airbnb.com/rooms/821223043903573522 | 20250926170004 | 2025-09-27 | city scrape | Incrível apartamento frente mar | Amazing 1-bedroom apartment facing the sea. Co... | NaN |

5 rows × 79 columns

```python
#colunas, linhas
df.shape
```

✓ 0.0s

```
(43068, 79)
```

# Principais Tratamentos

Antes da análise, os dados passaram por etapas de limpeza e transformação para garantir consistência e viabilizar a modelagem.

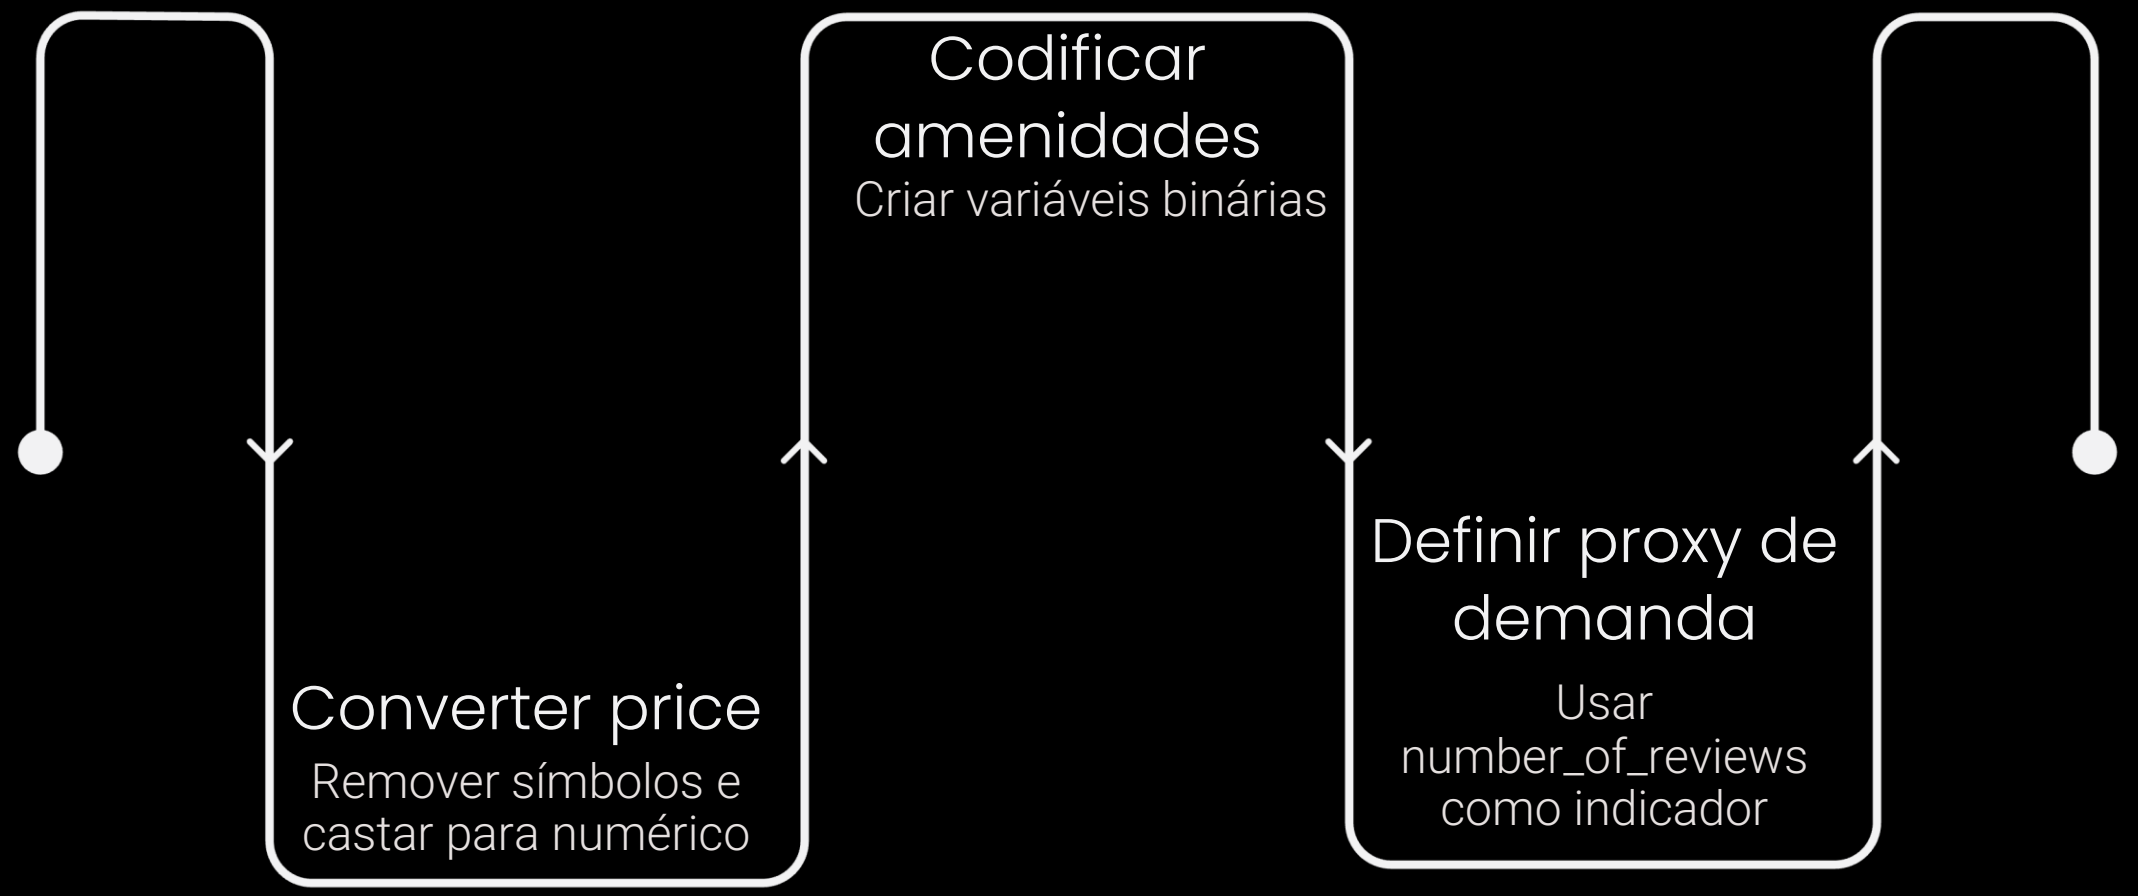


A conversão da coluna `price` removeu símbolos de moeda e realizou a conversão para numérico. As amenidades foram transformadas em variáveis binárias, e o número de reviews foi adotado como proxy de demanda por refletir o histórico de ocupação dos imóveis.

## Tratamento de PRICE

**Justificativa de Price:** Realizei o tratamento dos dados na coluna PRICE, que possuia caracteres especiais. Os removi e converti a coluna em float para melhorar a ánalise com base nos preç

```
df['price'].head(10)
```

626] ✓ 0.0s

```
0      $580.00
1    $1,900.00
2      $700.00
3          NaN
4      $500.00
5      $461.00
6          NaN
7      $281.00
8      $950.00
9      $450.00
Name: price, dtype: str
```

```
df['price'] = df['price'].replace(r'[\$,]', '', regex=True).astype(float)
```

627] ✓ 0.0s

```
df['price'].head(10)
```

628] ✓ 0.0s

```
0     580.0
1    1900.0
2     700.0
3       NaN
4     500.0
5     461.0
6       NaN
7     281.0
8     950.0
9     450.0
Name: price, dtype: float64
```

## Transformação de amenities

**Justificativa das amenities:** Optei por extrair as 5 amenities mais frequentes na base de dados pois elas representam a infraestrutura básica e o padrão mínimo esperado pela maioria dos hóspedes

```python
# 1. Removemos os colchetes e aspas da string usando regex
amenities_limpas = df['amenities'].str.replace(r'[\[\]"]', '', regex=True)

# 2. Separamos o texto por vírgulas para criar uma lista
amenities_listas = amenities_limpas.str.split(', ')

# 3.separa cada item da lista em uma linha temporária.
ranking_amenities = amenities_listas.explode().value_counts()

# Mostrando amenities que mais aparecem no Rio de Janeiro
display(ranking_amenities.head(5))
```

739] ✓ 0.6s

```
amenities
Kitchen                 35206
Wifi                    34973
Hot water               25261
Dishes and silverware   24148
Air conditioning        24106
Name: count, dtype: int64
```

```python
top_amenities = ranking_amenities.head(5).index.tolist()

import re
colunas_novas = []

for amenidade in top_amenities:
    nome_limpo = re.sub(r'[^a-zA-Z0-9]', '_', amenidade.lower())
    nome_coluna = f'has_{nome_limpo}'

    df[nome_coluna] = df['amenities'].str.contains(amenidade, case=False, na=False).astype(int)

    colunas_novas.append(nome_coluna)

df[['price', 'accommodates'] + colunas_novas].head(10)
```

740] ✓ 0.4s

| | price | accommodates | has_kitchen | has_wifi | has_hot_water | has_dishes_and_silverware | has_air_conditioning |
|---|---|---|---|---|---|---|---|
| 0 | 580.0 | 4 | 1 | 1 | 1 | 1 | 0 |
| 1 | 1900.0 | 2 | 1 | 1 | 0 | 0 | 1 |
| 2 | 700.0 | 4 | 1 | 0 | 0 | 0 | 1 |
| 4 | 500.0 | 4 | 1 | 1 | 0 | 0 | 1 |
| 5 | 461.0 | 6 | 1 | 1 | 1 | 1 | 1 |
| 7 | 281.0 | 2 | 1 | 1 | 1 | 1 | 0 |
| 8 | 950.0 | 2 | 1 | 1 | 1 | 1 | 1 |
| 9 | 450.0 | 4 | 0 | 1 | 1 | 0 | 0 |
| 10 | 1000.0 | 6 | 1 | 1 | 1 | 1 | 1 |
| 11 | 980.0 | 3 | 1 | 1 | 1 | 1 | 1 |

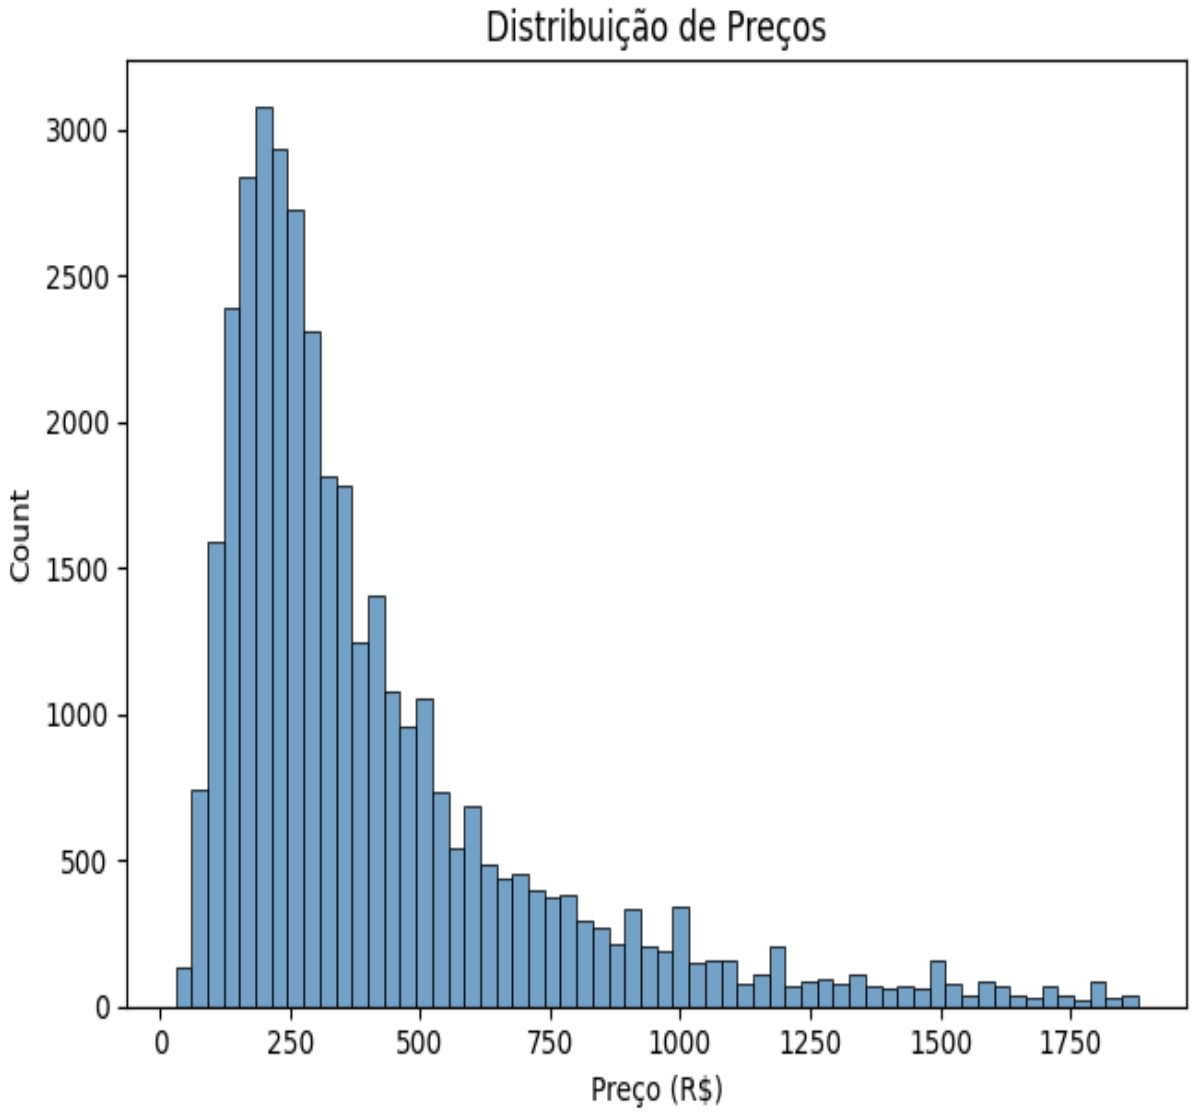


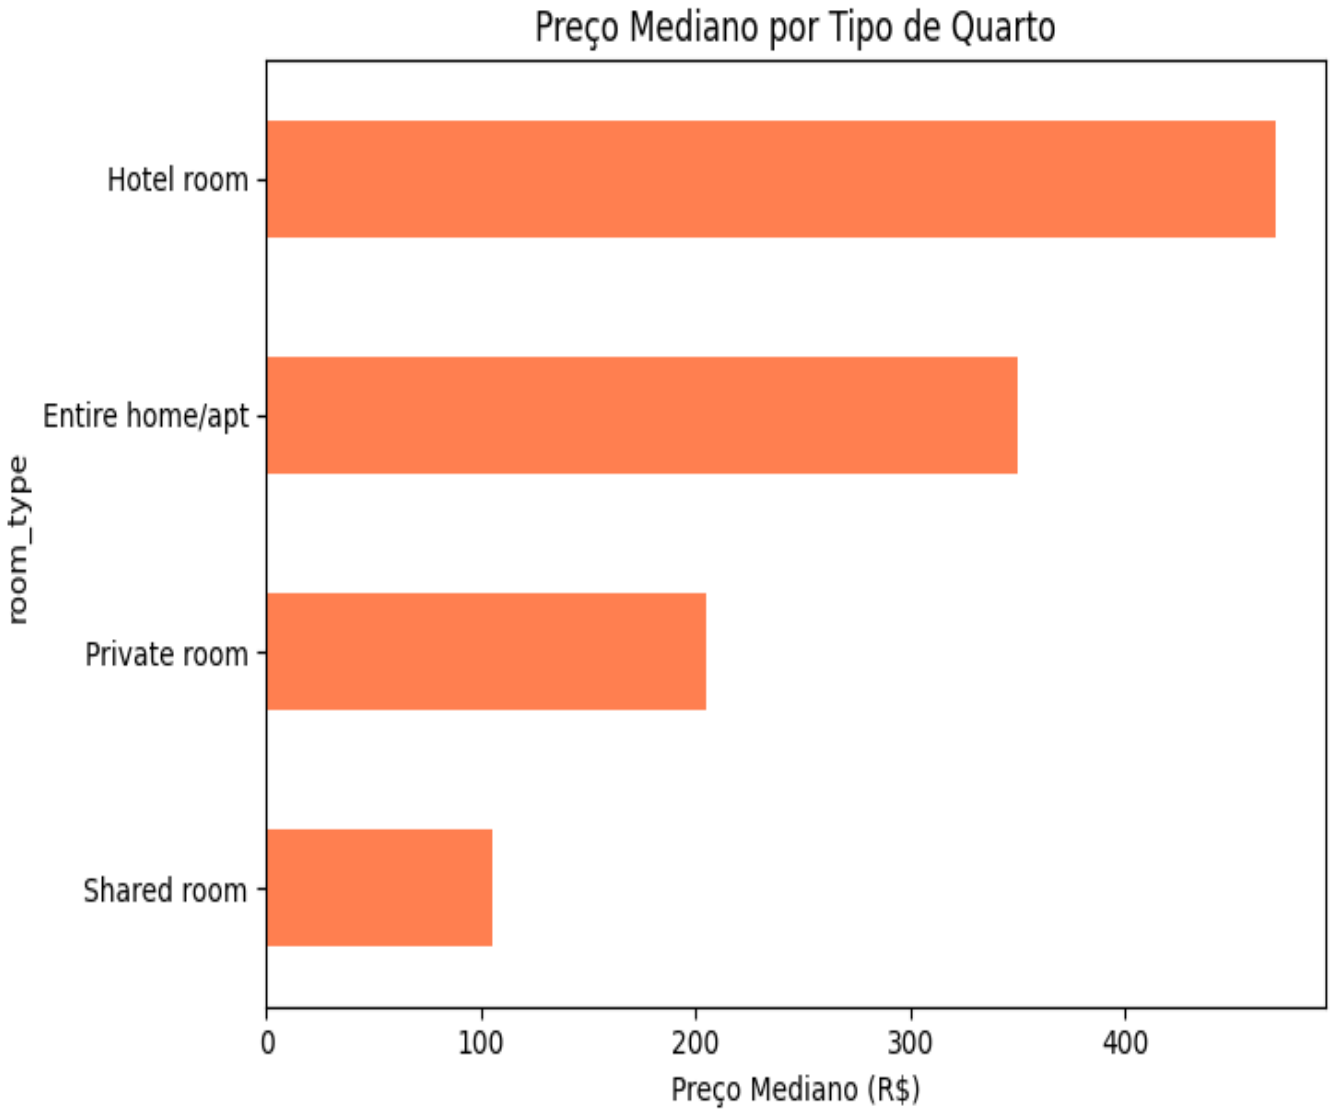


## Gráfico 1 - Distribuição de preços:

A distribuição de preços é assimétrica à direita, com a maioria dos anúncios concentrada entre R$100 e R$500. O pico está em torno de R$200-R$300, indicando que esse é o preço mais comum no mercado. A cauda longa à direita mostra a existência de imóveis de luxo que elevam a média, justificando o uso da mediana como medida mais representativa. (Caso utilize a média, a conta seria altamente influneciada)

## Gráfico 2 — Preço Mediano por Tipo de Quarto:

Hotel room apresenta o maior preço mediano (~R$450), seguido de Entire home/apt (R$350). Private room (R$200) e Shared room (R$100) são significativamente mais baratos. Isso reflete a lógica do mercado: acomodações completas e com serviços agregados comandam preços maiores, enquanto quartos compartilhados atendem um público mais sensível ao preço.

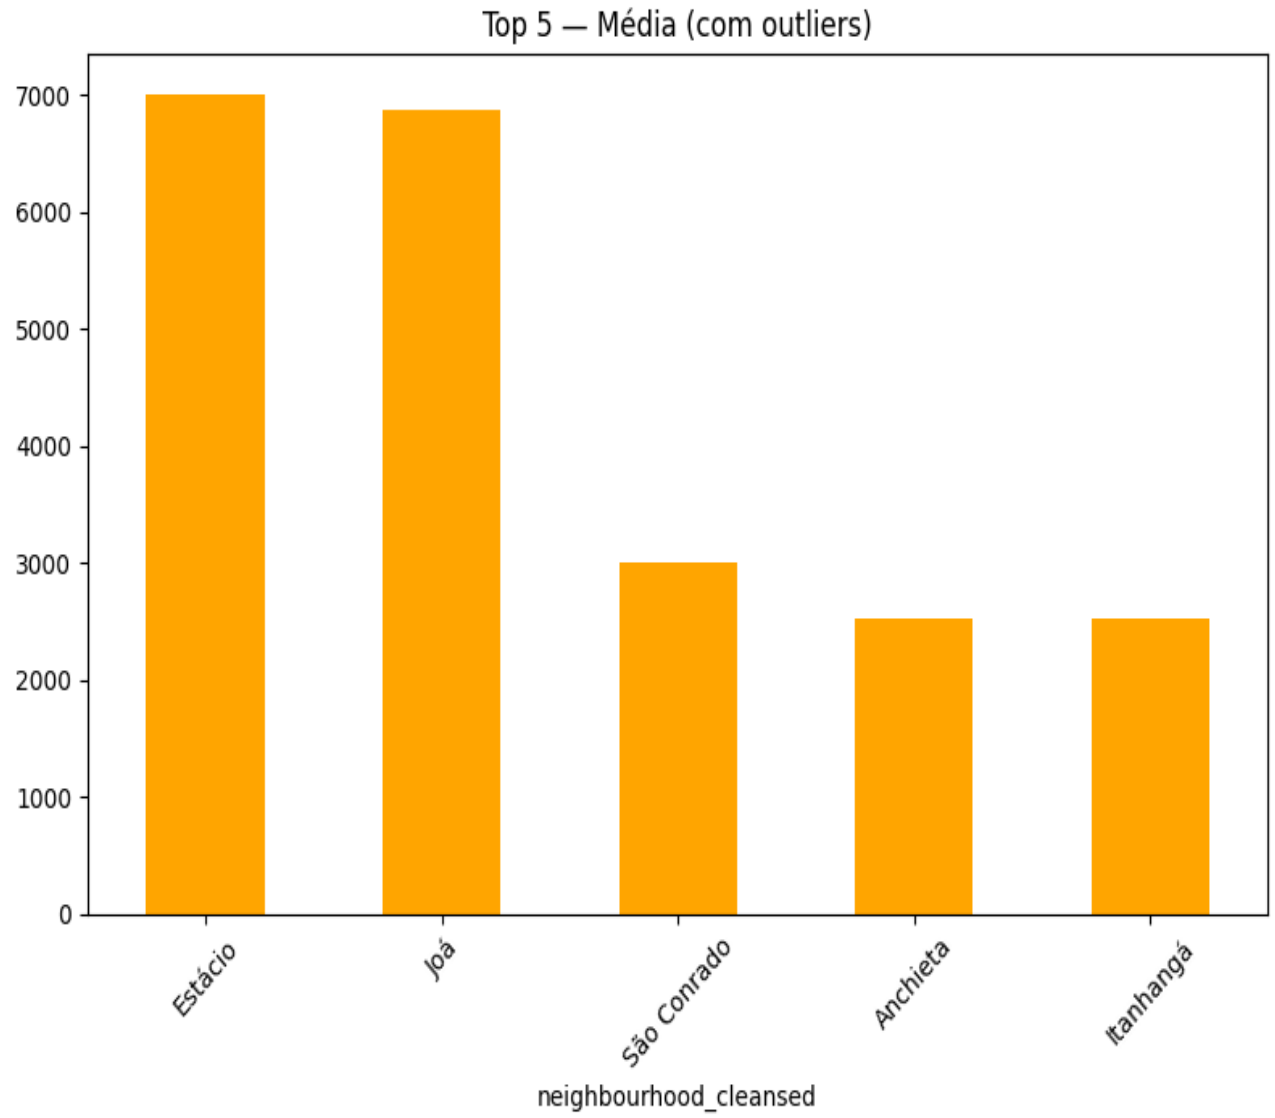


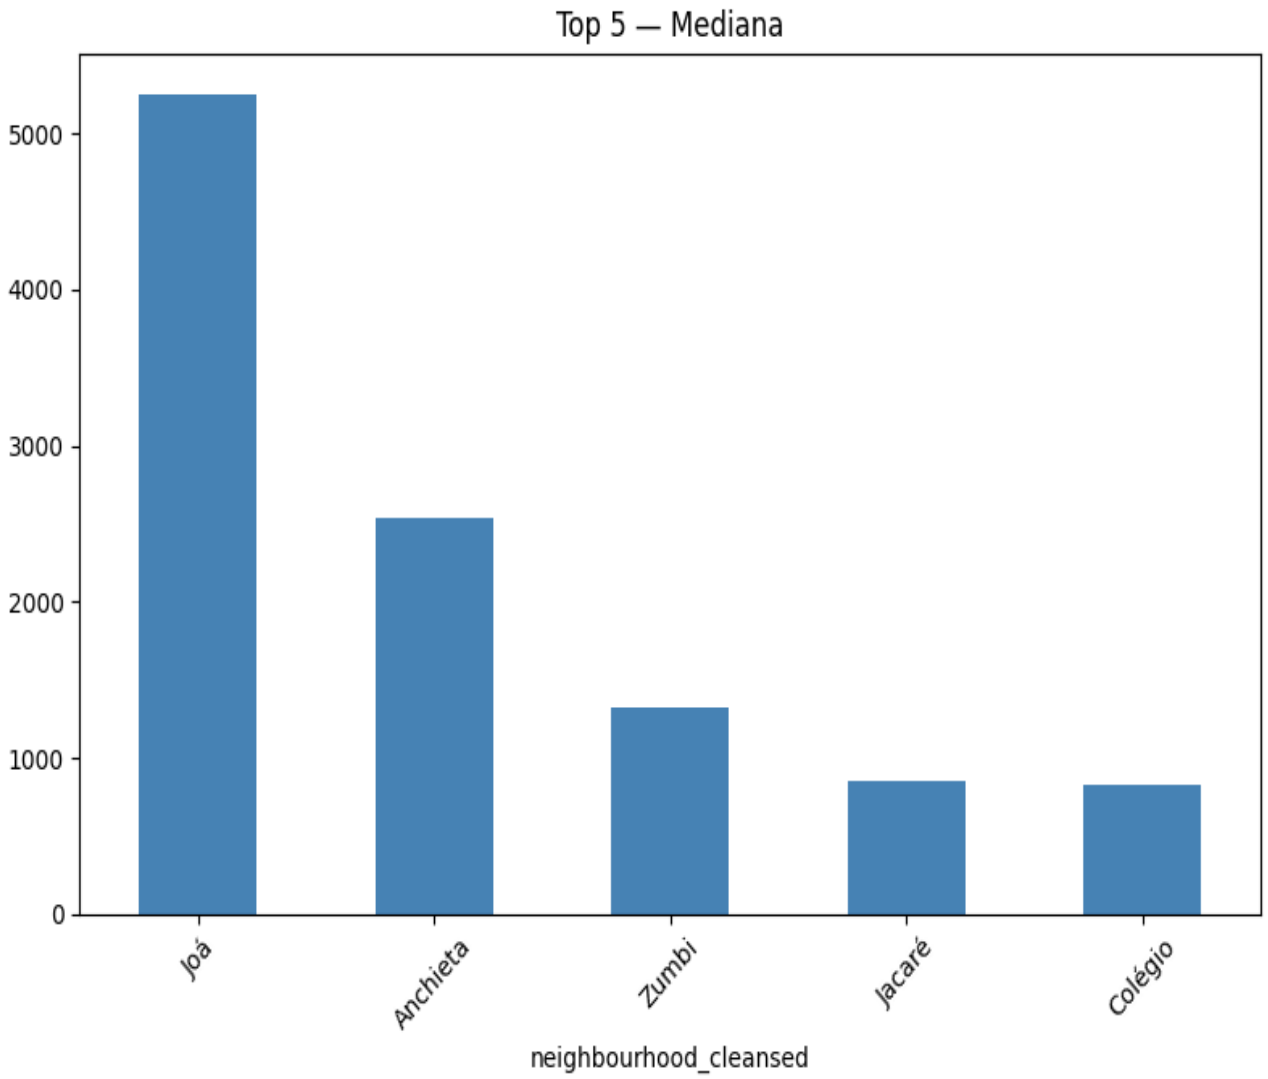


## Gráfico 3 — Top 5 Bairros por Preço Médio:

A média indica Estácio e Joá como os bairros mais caros, porém há distorção nos dados. No caso do Estácio, um valor extremamente alto (outlier) eleva artificialmente a média, não representando a realidade do bairro.

## Gráfico 3.1 — Top 5 Bairros por Preço mediano:

A mediana elimina o impacto de outliers e mostra valores mais realistas. Assim, os bairros apresentados refletem melhor o preço típico das diárias.

# Identificação de outliers

```python
df_estacio = df[df['neighbourhood_cleansed'] == 'Estácio']

media_estacio = df_estacio['price'].mean()
mediana_estacio = df_estacio['price'].median()

moda_estacio = df_estacio['price'].mode()[0]

print(f"--- Valores de Preço no Bairro Estácio ---")
print(f"Média (Average): R$ {media_estacio:.2f}")
print(f"Mediana (Valor do meio): R$ {mediana_estacio:.2f}")
print(f"Moda (Preço mais comum): R$ {moda_estacio:.2f}")

anuncios_caros = df_estacio.sort_values(by='price', ascending=False)

display(anuncios_caros[['id', 'name', 'room_type', 'price']].head(5))
```

✓ 0.0s

```
--- Valores de Preço no Bairro Estácio ---
Média (Average): R$ 7003.15
Mediana (Valor do meio): R$ 160.00
Moda (Preço mais comum): R$ 160.00
```

| | id | name | room_type | price |
|---|---|---|---|---|
| 7624 | 30033272 | Apartamento em Rio de Janeiro | Entire home/apt | 500000.0 |
| 23551 | 1071216377896851973 | Apt arejado, sol da manhã | Private room | 1485.0 |
| 33742 | 1338558066930251191 | Em frente ao metrô | Entire home/apt | 972.0 |
| 37042 | 1389833350160373079 | Hospedagem Santo Antônio | Private room | 900.0 |
| 35733 | 1363181864923328390 | quarto para casal | Private room | 765.0 |

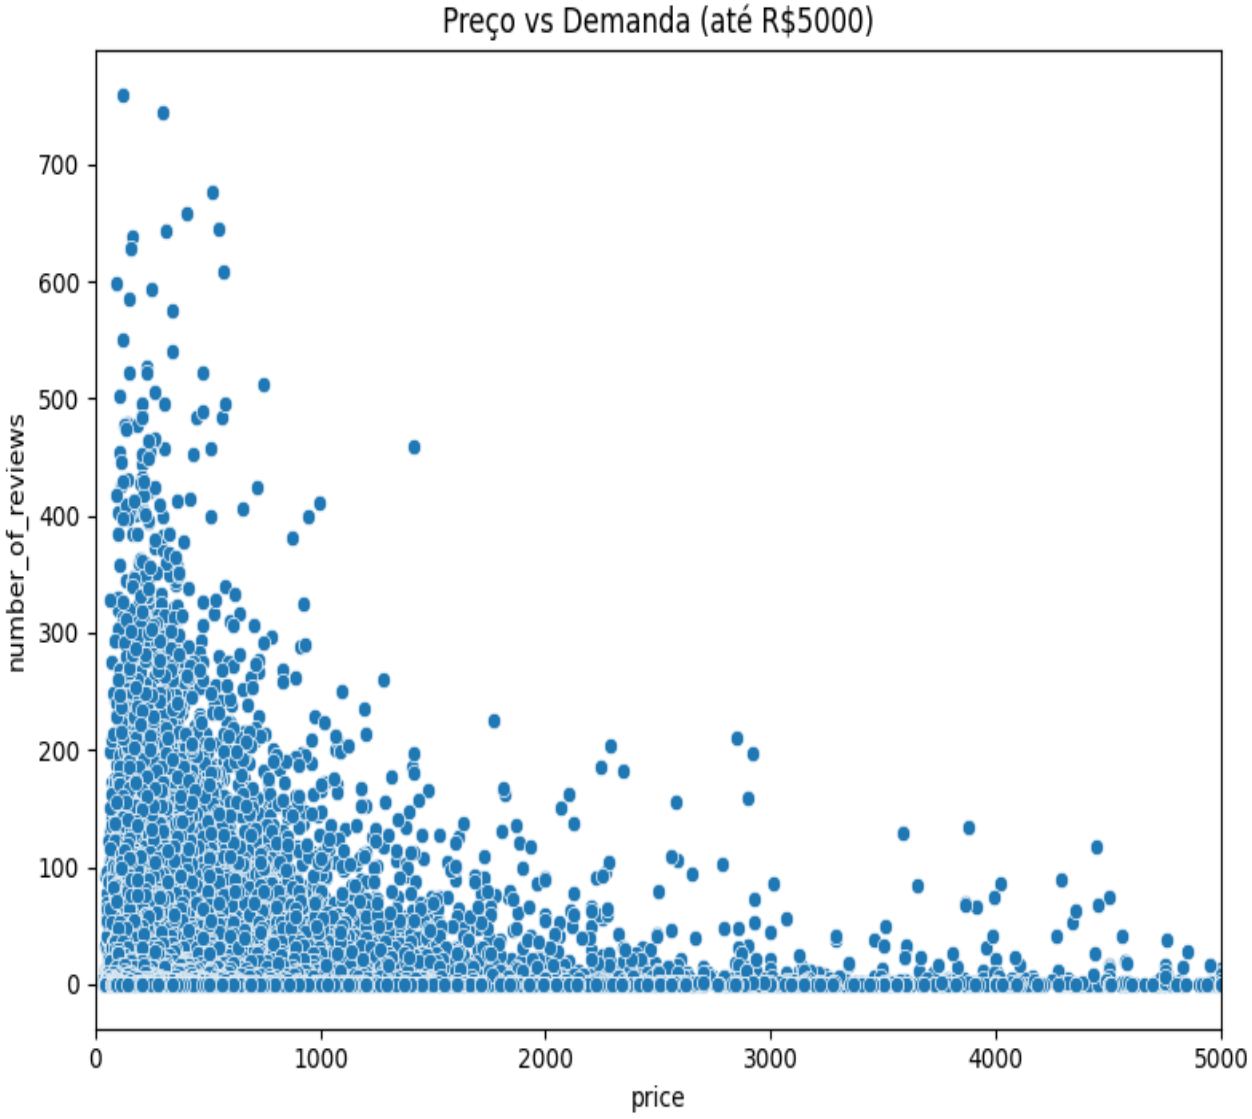


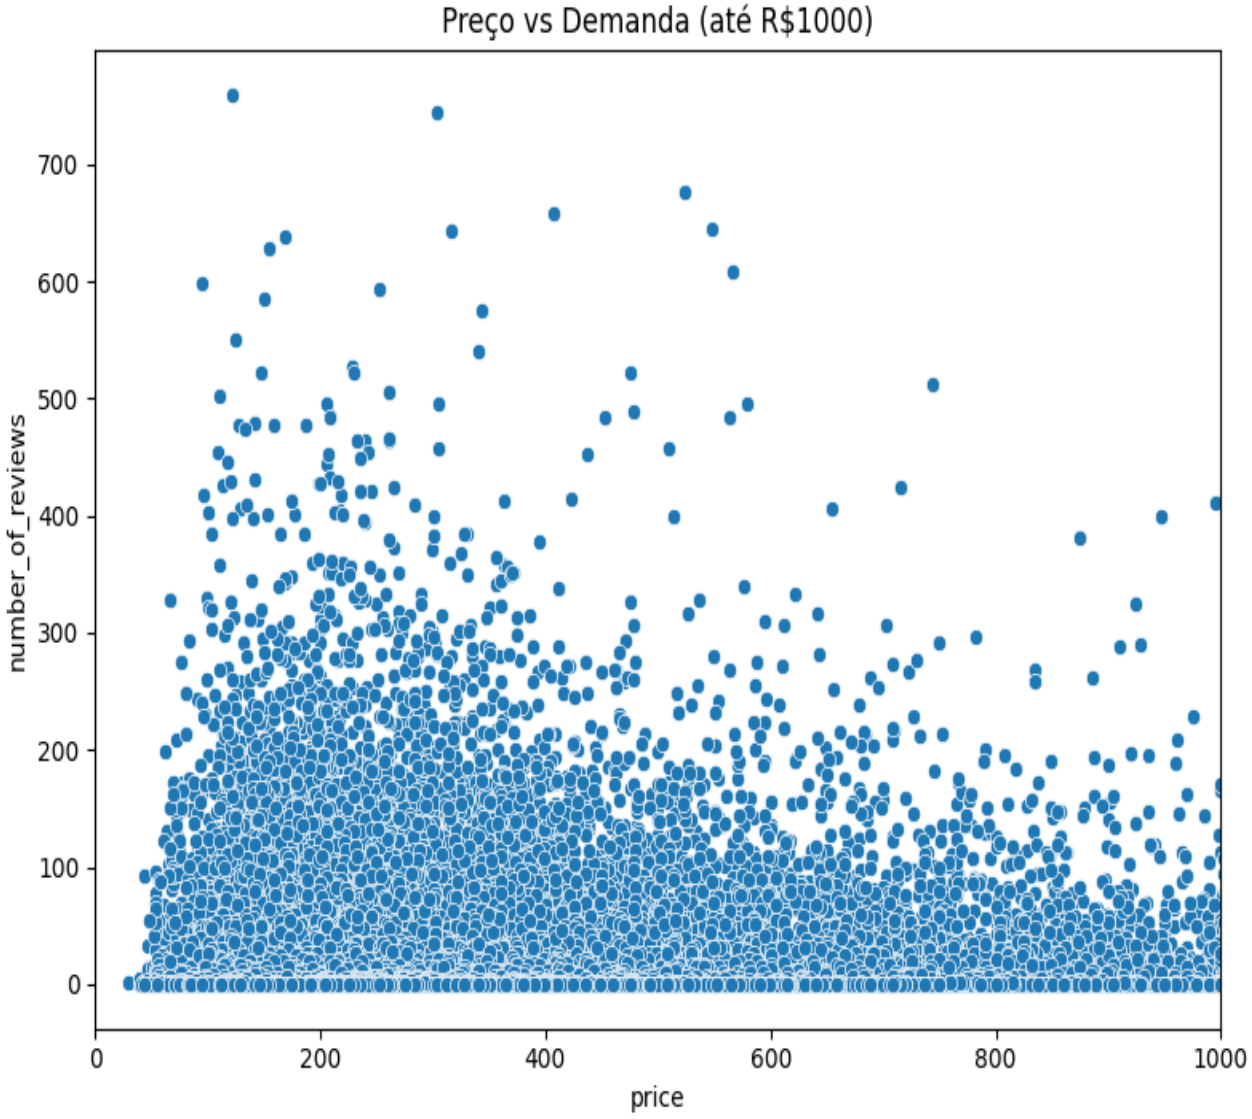


## Gráfico 4 - Demanda de procura

A quantidade de demanda está diretamente relacionada ao preço das diárias, a busca por diárias em valores mais acessíveis (R$150 -R$ 450) é muito maior do que para valores mais elevados

```python
# --- Teste: amenities vs Preço ---

df['qtd_amenities'] = df[colunas_novas].sum(axis=1)
baixa = df[df['qtd_amenities'] <= 2]['price']
alta = df[df['qtd_amenities'] > 2]['price']

from scipy import stats

# H0: preço é igual independentemente da quantidade de amenities
# H1: imóveis com mais amenities são mais caros

stat, p = stats.mannwhitneyu(alta, baixa, alternative='greater')

print("--- Teste: amenities vs Preço ---")
print("amenities consideradas:", colunas_novas)
print(f"p-valor: {p:.4f}")

if p < 0.05:
    print("Conclusão: Imóveis com mais amenities são significativamente mais caros.")
else:
    print("Conclusão: Não há diferença estatística no preço.")
```

[747] ✓ 0.0s

```
--- Teste: amenities vs Preço ---
amenities consideradas: ['has_kitchen', 'has_wifi', 'has_hot_water', 'has_dishes_and_silverware', 'has_air_conditioning']
p-valor: 0.0000
Conclusão: Imóveis com mais amenities são significativamente mais caros.
```

```python
# --- Teste 2: Bairros têm preços diferentes? ---
# H0: preço médio é igual entre os bairros
# H1: pelo menos um bairro tem preço diferente

# Agrupando apenas bairros com um volume bom de anúncios (mais de 30)
grupos_bairros = [g['price'].values for _, g in df.groupby('neighbourhood_cleansed') if len(g) >= 30]

# Calculando a estatística
stat, p = stats.kruskal(*grupos_bairros)

print(f"\n--- Teste 2: Impacto da Localização no Preço ---")
print(f"p-valor: {p:.4f}")

if p < 0.05:
    print("Conclusão: O bairro afeta fortemente o valor da diária!")
    print("Existe uma diferença de preços real e estatisticamente comprovada entre as diferentes regiões.")
else:
    print("Conclusão: NÃO existe diferença de preço comprovada entre os bairros.")
    print("Estatisticamente, os anfitriões cobram valores parecidos independente da região analisada.")
```

✓ 0.0s

```
--- Teste 2: Impacto da Localização no Preço ---
p-valor: 0.0000
Conclusão: O bairro afeta fortemente o valor da diária!
Existe uma diferença de preços real e estatisticamente comprovada entre as diferentes regiões.
```

```python
from scipy import stats

# --- Teste 3: Superhost vs Demanda ---
# H0: número de reviews é igual entre superhosts e comuns
# H1: superhosts têm mais reviews (maior demanda)

superhosts = df[df['host_is_superhost'] == 't']['number_of_reviews']
comuns = df[df['host_is_superhost'] == 'f']['number_of_reviews']

stat, p = stats.mannwhitneyu(superhosts, comuns, alternative='greater')

print("--- Teste 3: Superhost vs Demanda ---")
print(f"p-valor: {p:.4f}")

if p < 0.05:
    print("Conclusão: Superhosts têm significativamente mais avaliações.")
    print("Isso indica maior demanda para esses anúncios.")
else:
    print("Conclusão: Não há diferença estatisticamente significativa.")
```

✓ 0.0s

```
--- Teste 3: Superhost vs Demanda ---
p-valor: 0.0000
Conclusão: Superhosts têm significativamente mais avaliações.
Isso indica maior demanda para esses anúncios.
```

```python
# --- Diferença entre superhost e comuns ---
agg_dict = {
    'id': 'count',
    'price': 'median',
    'number_of_reviews': 'mean'
}
for col in colunas_novas:
    agg_dict[col] = 'mean'
resumo_host = df.groupby('host_is_superhost').agg(agg_dict)
resumo_host = resumo_host.rename(columns={
    'id': 'total_anuncios',
    'price': 'preco_mediano',
    'number_of_reviews': 'reviews_medio'
})
for col in colunas_novas:
    resumo_host = resumo_host.rename(columns={col: f'perc_{col.replace("has_", "")}'})
colunas_perc = [col for col in resumo_host.columns if col.startswith('perc_')]
resumo_host[colunas_perc] = (resumo_host[colunas_perc] * 100).round(1)
resumo_host['preco_mediano'] = resumo_host['preco_mediano'].round(2)
resumo_host['reviews_medio'] = resumo_host['reviews_medio'].round(1)

display(resumo_host)
```

✓ 0.0s

| host_is_superhost | total_anuncios | preco_mediano | reviews_medio | perc_kitchen | perc_wifi | perc_hot_water | perc_dishes_and_silverware | perc_air_conditioning |
|---|---|---|---|---|---|---|---|---|
| f | 23710 | 349.0 | 14.1 | 90.8 | 94.5 | 55.4 | 51.6 | 66.4 |
| t | 13673 | 283.0 | 49.6 | 92.5 | 98.8 | 83.4 | 80.3 | 58.3 |

# Resultados:

Mais amenidades → maior preço

Bairro influencia preço

Superhosts têm maior demanda e melhores alojamentos

# Conclusão:

- Preço depende de localização, tipo e amenidades
- Imóveis mais baratos têm maior procura
- Superhosts apresentam maior desempenho

# Limitação:

- Uso de reviews como proxy de demanda
- Outliers