

UNIVERSIDADE TECNOLÓGICA FEDERAL DO PARANÁ

Campus Campo Mourão

Tópicos em Engenharia de Software - Ciência de Dados

Prof. Eduardo Pena

Aluno: Kaiky de Souza Lima

RA: 2864568

Trabalho: Imputação de Valores Ausentes

Campo Mourão, 2026

1. Introdução

Valores ausentes são uma realidade comum em conjuntos de dados do mundo real e podem comprometer significativamente o desempenho de modelos preditivos quando não tratados de forma adequada. Este trabalho avalia, de forma experimental, como diferentes técnicas de imputação se comportam sob diferentes mecanismos e níveis de ausência, medindo tanto a qualidade da imputação em si quanto o impacto no desempenho dos modelos.

A motivação para comparar os mecanismos MCAR (Missing Completely At Random), MAR (Missing At Random) e MNAR (Missing Not At Random) é que cada um deles apresenta diferentes padrões de ausência que podem ser mais ou menos prejudiciais dependendo da técnica de imputação e do dataset. Em MCAR, a ausência é completamente aleatória; em MAR, depende de outras variáveis observadas; em MNAR, depende do próprio valor ausente, tornando-o o cenário mais desafiador.

O protocolo experimental utiliza a biblioteca Jenga para injeção controlada de valores ausentes, 10 técnicas de imputação (incluindo o miceforest como método externo ao scikit-learn), 4 modelos preditivos (incluindo o LightGBM como modelo tabular de estado da arte), 3 seeds de repetição e 7 níveis de ausência (1% a 30%), totalizando 7.386 configurações avaliadas em 4 datasets.

2. Datasets

Quatro datasets públicos foram utilizados, abrangendo problemas de classificação e regressão:

Dataset	Tarefa	Variavel-Alvo	Linhas Orig.	Colunas	Nulos Orig.	Linhas Completas
adult	Classificação	income	48.842	15	6.465	45.222
bank_marketing	Classificação	y	45.211	17	~0	45.211
air_quality_uci	Regressão	NO2(GT)	9.358	15	5.085	6.941
communities_crime	Regressão	ViolentCrimesPerPop	2.215	128	1.320	1.901

Tabela 1: Resumo dos quatro datasets utilizados.

Os datasets adult e bank_marketing são problemas de classificação binária com forte desbalanceamento de classes. Os datasets air_quality_uci e communities_crime são problemas de regressão, com o primeiro apresentando alta correlação entre as variáveis e o segundo sendo caracterizado por grande número de atributos.

3. Métodos

3.1 Imputadores do scikit-learn

Foram implementados os seguintes métodos:

- SimpleImputer com mean: substitui valores ausentes pela média da coluna
- SimpleImputer com median: substitui pela mediana, mais robusta a outliers
- SimpleImputer com most_frequent: substitui pelo valor mais frequente (útil para categóricas)
- SimpleImputer com constant: substitui por constante (zero para numéricas)
- KNNImputer com k=3, k=5 e k=7: imputação baseada nos k vizinhos mais próximos

- IterativeImputer: imputação multivariada iterativa com max_iter=5, tol=0.01, initial_strategy=mean, skip_complete=True
- dropna: baseline que remove as linhas com valores ausentes

3.2 Método externo: miceforest

O miceforest foi escolhido como método externo por implementar o algoritmo MICE (Multiple Imputation by Chained Equations) com Random Forests como estimadores internos. Essa abordagem é considerada robusta pois preserva a estrutura multivariada dos dados e produz múltiplas imputações que capturam a incerteza. Foram utilizadas iterations=1 e max_cols=30 para viabilidade computacional.

3.3 Modelos preditivos

Para classificação, foram usados: Regressão Logística, Random Forest Classifier e LightGBM. Para regressão: Ridge Regression, Random Forest Regressor e LightGBM. O LightGBM foi escolhido como modelo tabular adicional por ser eficiente em datasets maiores, suportar nulos nativamente e apresentar desempenho de estado da arte em dados tabulares em benchmarks recentes.

4. Protocolo Experimental

O protocolo seguiu as seguintes etapas para cada dataset: (1) carregamento e normalização de marcadores de ausência; (2) criação de versão completa removendo linhas com nulos; (3) injeção controlada de valores ausentes nos atributos de entrada usando Jenga; (4) divisão treino/teste (80/20); (5) ajuste do imputador apenas no treino; (6) aplicação no treino e no teste; (7) treinamento dos modelos; (8) avaliação no teste.

Mecanismos: MCAR, MAR e MNAR, implementados via biblioteca Jenga.

Percentuais: 1%, 5%, 10%, 15%, 20%, 25% e 30%.

Repetições: 3 seeds (42, 123, 456). O relatório apresenta media e desvio padrão.

Métricas de classificação: Accuracy, Macro F1, Weighted F1.

Métricas de regressão: MAE, RMSE, R2.

Qualidade da imputação: MAE e RMSE nas posições removidas artificialmente (numéricas); acurácia de imputação (categóricas).

5. Resultados

5.1 Comparação geral: baseline × dropna × melhor imputador

A Tabela abaixo compara os três cenários principais para cada dataset, usando LightGBM:

Dataset	Baseline	Dropna injetado	Melhor imputador	Valor
adult	0.8328	0.8065	simple_const	0.8222
bank_marketing	0.8545	0.8099	simple_mean	0.8479
air_quality_uci	0.9960	-0.9002	iterative	0.9908
communities_crime	0.6280	0.5155	iterative	0.6255

Tabela 8: Comparação entre baseline, dropna e melhor imputador (LightGBM).

O dropna causou perdas significativas em todos os datasets, especialmente no air_quality_uci onde o R^2 despencou de 0.996 para -0.900 — um colapso total. A imputação recuperou quase todo o desempenho perdido em todos os datasets, com o iterative sendo o melhor em regressão e o simple_mean/const em classificação.

5.2 Impacto do mecanismo de ausência

A tabela abaixo apresenta a acurácia média (LightGBM, média de todos os imputadores e taxas) por mecanismo nos datasets de classificação:

Dataset	MCAR	MAR	MNAR
adult	0.816	0.811	0.825
bank_marketing	0.826	0.847	0.846

Tabela 2: Acurácia média por mecanismo (LightGBM, classificação).

Para regressão (R^2 , LightGBM):

Dataset	MCAR	MAR	MNAR
air_quality_uci	0.901	0.928	0.538
communities_crime	0.619	0.615	0.616

Tabela 3: R^2 médio por mecanismo (LightGBM, regressão).




Figura 2: Efeito do mecanismo de missingness por dataset (LightGBM, média dos imputadores).

Esta figura compara o impacto de MCAR, MAR e MNAR ao longo das taxas de ausência. Em adult, os três mecanismos degradam o desempenho de forma similar, com MAR apresentando queda abrupta a 25-30%. No air_quality_uci, o MNAR causa colapso total do R2 a partir de 25%, chegando a valores negativos — evidenciando que a ausência dos valores mais extremos distorce fundamentalmente a distribuição do dataset. O communities_crime apresenta comportamento estável em todos os mecanismos.

O resultado mais notável é o forte impacto do MNAR no dataset air_quality_uci, com R2 médio de apenas 0.538 contra 0.901 (MCAR) e 0.928 (MAR). Isso ocorre porque nesse dataset os valores mais extremos tendem a ser removidos, distorcendo significativamente a distribuição.

5.3 Impacto do percentual de ausência

A tabela abaixo mostra a degradação do desempenho com o aumento da taxa de ausência (LightGBM, média de mecanismos e imputadores):

Taxa	adult Acc.	bank_mkt Acc.	air_quality R2	communities R2
1%	0.833	0.852	0.996	0.623
5%	0.829	0.848	0.985	0.622
10%	0.827	0.841	0.977	0.621
15%	0.821	0.836	0.956	0.619
20%	0.818	0.835	0.849	0.618
25%	0.808	0.830	0.852	0.617

30%	0.785	0.826	-0.108	0.610
-----	-------	-------	--------	-------

Tabela 4: Desempenho por taxa de ausência.

O dataset `air_quality_uci` foi o mais sensível, com queda de R2 de 0.996 para -0.108 entre 1% e 30% de ausência. Isso ocorre principalmente com o mecanismo MNAR a 30%, onde o dropna remove quase todos os dados. O `communities_crime` foi o mais estável, com queda de apenas 0.013 no R2. Os datasets de classificação apresentaram degradação moderada.




Figura 1: Desempenho por percentual de nulos (MCAR, LightGBM) — comparação entre imputadores.

Esta figura mostra como cada imputador se comporta com o aumento da taxa de ausência sob MCAR. No `adult`, todos os métodos de imputação mantêm desempenho próximo entre si, com exceção do `dropna` (linha cinza), que apresenta queda abrupta a partir de 20%. No `air_quality_uci`, o `dropna` injetado colapsa para R2 negativo (inferior a -3) a 25% de ausência, enquanto todos os imputadores mantêm R2 acima de 0.95. No `communities_crime`, o comportamento é mais estável, sem diferença expressiva entre os imputadores.

5.4 Comparação entre imputadores

A tabela abaixo apresenta a acurácia média por imputador nos datasets de classificação (LightGBM, média de mecanismos, taxas e seeds):

Imputador	adult Acc.	bank_mkt Acc.	Rank Geral
simple_mean	0.822	0.848	1o
iterative	0.819	0.847	2o

simple_median	0.821	0.847	3o
simple_freq	0.819	0.845	4o
knn_7	0.818	0.843	5o
knn_5	0.817	0.842	6o
knn_3	0.816	0.839	7o
simple_const	0.815	0.837	8o
dropna	0.807	0.810	9o
miceforest	0.808	0.819	10o

Tabela 5: Acurácia média por imputador (LightGBM, classificacao).

Para regressão (R2, LightGBM):

Imputador	air_quality R2	communities R2
simple_mean	0.991	0.620
simple_median	0.990	0.620
iterative	0.991	0.626
knn_7	0.963	0.615
simple_const	0.984	0.621
miceforest	0.826	0.597
dropna	-0.900	0.515

Tabela 6: R2 médio por imputador (LightGBM, regressão).




Figura 3: Heatmap mecanismo x imputador (LightGBM, media por tarefa).

O heatmap confirma a superioridade dos métodos simples sobre o miceforest em todos os mecanismos. Em classificação, SimpleImputer (mean e const) e IterativeImputer atingem Weighted F1 de 0.856 com MNAR, enquanto o miceforest fica em 0.834. Em regressão, o dropna com MNAR colapsa para $R^2 = -3.087$, evidenciando o risco de remoção de linhas sob

ausência não aleatória. O iterative obteve o melhor R2 (0.809 em MAR), superando ligeiramente os demais.




Figura 5: Ganho sobre SimpleImputer (mean) — metodos robustos vs simples (LightGBM).

Esta figura mostra o ganho diferencial de KNN k=5, IterativeImputer e MICEforest em relação ao SimpleImputer (mean). O IterativeImputer mantém-se próximo a zero em todos os datasets, com pequeno ganho no communities_crime (até +0.02 de R2). O KNN k=5 também é próximo ao baseline simples. O miceforest é consistentemente negativo em todos os datasets e taxas, chegando a -0.30 de R2 no air_quality_uci com 15% de ausência.

5.5 Qualidade da imputação

A qualidade da imputação numérica (MAE nas posições removidas, dataset adult) revelou resultado contraintuitivo: o simple_median obteve o menor MAE de imputação (12.740), seguido pelo simple_mean (12.944) e pelo iterative (12.995). O miceforest, apesar de ser o método mais sofisticado, obteve MAE de imputação de 18.560 - o pior entre os métodos com imputação efetiva. O simple_const obteve o pior resultado geral (30.941).




Figura 4: Qualidade da imputação vs desempenho preditivo (LightGBM).

Esta figura mostra a relação entre a qualidade da imputação (eixo X) e o desempenho preditivo (eixo Y). Em classificação, não há correlação clara entre melhor acurácia de imputação e melhor Weighted F1 — os pontos se distribuem horizontalmente sem padrão definido. Em regressão, observa-se que o miceforest (pontos marrons) concentra-se em regiões de MAE alto e R^2 variável, enquanto os métodos simples atingem R^2 próximo a 1.0 com MAE baixo. Isso confirma que qualidade de imputação não prediz necessariamente desempenho preditivo.

5.6 Comparação entre modelos

Para classificação, o LightGBM obteve a melhor acurácia média (0.828), seguido pelo Random Forest (0.809) e Regressão Logística (0.806). Para regressão, o Random Forest obteve o melhor R^2 médio (0.787), seguido pela Ridge Regression (0.740) e pelo LightGBM (0.707). O resultado inesperado do LightGBM em regressão deve-se ao forte impacto do MNAR no `air_quality_uci`, que distorce a média.




Figura 6: Comparativo de modelos por percentual de nulos (MCAR, média dos imputadores).

Esta figura compara o desempenho dos três modelos por percentual de ausência sob MCAR. O LightGBM domina em classificação (adult e bank_marketing) em todos os níveis. Em regressão, o Random Forest é mais estável que o LightGBM no air_quality_uci, onde o LightGBM sofre queda abrupta de R² a partir de 25% de ausência. O communities_crime apresenta comportamento similar entre os modelos, com ligeira vantagem do LightGBM nas taxas mais baixas.

6. Discussão

Pergunta 1: O desempenho cai de forma semelhante em MCAR, MAR e MNAR?

Não. O comportamento varia significativamente por dataset. No adult e bank_marketing, as diferenças entre mecanismos foram pequenas (menos de 2 pontos de acurácia). Já no air_quality_uci, o MNAR causou uma queda drástica no R² (0.538 vs 0.901 no MCAR), demonstrando que o mecanismo mais prejudicial depende fortemente das características do dataset.

Pergunta 2: Quais datasets foram mais sensíveis ao aumento do percentual de nulos?

O air_quality_uci foi de longe o mais sensível: queda de R² de 0.996 para -0.108 entre 1% e 30%, uma variação de 1.104 pontos. O communities_crime foi o mais estável (variação de apenas 0.013). Os datasets de classificação apresentaram degradação moderada: adult perdeu 0.048 pontos de acurácia e bank_marketing apenas 0.026.

Pergunta 3: Métodos simples foram competitivos em algum cenário?

Sim, e de forma surpreendente os métodos simples foram os mais competitivos em geral. O `simple_mean` obteve o melhor desempenho médio em classificação (0.822 no `adult`, 0.848 no `bank_marketing`) e o segundo melhor em regressão ($R^2=0.991$ no `air_quality_uci`). Métodos simples são especialmente eficazes em datasets grandes onde a média/mediana é um estimador estável.

Pergunta 4: Quando KNNImputer ou IterativeImputer superaram os métodos simples?

O `IterativeImputer` superou o `simple_mean` no `communities_crime` ($R^2=0.626$ vs 0.620), dataset com muitas variáveis correlacionadas onde a imputação multivariada é mais vantajosa. O `KNNImputer` com $k=7$ obteve resultados próximos ao `IterativeImputer` em taxas baixas (1-5%), mas ficou atrás em taxas altas. Em classificação, os ganhos do KNN e `IterativeImputer` sobre o `simple_mean` foram marginais (menos de 0.002 de acurácia).

Pergunta 5: Os métodos externos superaram os tradicionais?

Não. O `miceforest` obteve desempenho inferior ao `simple_mean` em todos os datasets: -0.014 de acurácia no `adult`, -0.029 no `bank_marketing`, -0.165 de R^2 no `air_quality_uci` e -0.023 no `communities_crime`. Além disso, o `miceforest` também obteve o pior MAE de imputação (18.560 vs 12.740 do `simple_median` no `adult`). O custo computacional muito maior não se traduziu em ganho de desempenho.

Pergunta 6: A melhor qualidade de imputação levou ao melhor desempenho preditivo?

Não. A correlação entre MAE de imputação e acurácia preditiva no `adult` foi de apenas -0.099, praticamente nula. O `simple_median` obteve o menor MAE de imputação (12.740) mas ficou em 3o lugar em acurácia. O `miceforest` teve o pior MAE de imputação (18.560) e também o pior desempenho preditivo, mas por razões diferentes: o `miceforest` subamostra colunas, o que pode introduzir ruído sistemático.

Pergunta 7: O modelo tabular adicional mudou as conclusões?

Parcialmente. O `LightGBM` foi o melhor modelo em classificação, confirmando seu status de estado da arte em dados tabulares. Em regressão, porém, o `Random Forest` superou o `LightGBM`, especialmente no `air_quality_uci`. As conclusões sobre os imputadores se mantiveram independentemente do modelo escolhido: `simple_mean` e `iterative` foram consistentemente superiores ao `miceforest`.

Pergunta 8: O comportamento foi diferente entre classificação e regressão?

Sim. Os datasets de classificação foram mais robustos a valores ausentes, com degradação moderada e comportamento mais previsível. Os datasets de regressão, especialmente o `air_quality_uci`, foram muito mais sensíveis - particularmente ao mecanismo MNAR. O `dropna` foi especialmente prejudicial em regressão ($R^2=-0.900$ em média no `air_quality_uci` vs 0.807 em classificação no `adult`).

Pergunta 9: Houve algum resultado inesperado?

Dois resultados foram inesperados. Primeiro, o `miceforest` - método sofisticado baseado em `Random Forests` - obteve desempenho consistentemente inferior ao `simple_mean`. Isso pode ser explicado pelo limite de `max_cols=30` (necessário por limitação computacional) e `iterations=1`, que podem não ser suficientes para capturar toda a estrutura multivariada. Segundo o `dropna` com MNAR em alta taxa (30%) chegou a $R^2=-0.900$ no `air_quality_uci`,

pior que um modelo constante, pois as linhas removidas eram justamente as mais informativas.

7. Ameaças a Validade

- Limitações dos datasets: apenas 4 datasets foram avaliados, podendo não ser representativos de todos os contextos.
- Injeção artificial de nulos: a injeção controlada pode não refletir padrões reais de ausência encontrados em produção.
- Custo computacional: o miceforest foi executado com `iterations=1` e `max_cols=30`, configurações reduzidas em relação ao ideal.
- Sensibilidade a hiper parâmetros: os modelos preditivos foram usados com configurações padrão, sem otimização de hiper parâmetros por dataset.
- Variabilidade entre seeds: apesar de 3 seeds, alguns cenários apresentaram alta variância, especialmente com MNAR em taxas altas.

8. Conclusão

Este trabalho avaliou 10 técnicas de imputação em 4 datasets, 3 mecanismos e 7 taxas de ausência, totalizando 7.386 configurações. Os principais achados são:

- Métodos simples (`simple_mean`, `simple_median`) foram surpreendentemente competitivos, superando o miceforest em todos os cenários avaliados.
- O mecanismo MNAR foi o mais prejudicial, especialmente em datasets de regressão com variáveis altamente correlacionadas.
- O dropna é perigoso em taxas altas: com 30% de ausência e MNAR, pode levar a R^2 negativo em regressão.
- A qualidade da imputação não prediz diretamente o desempenho preditivo (correlação de -0.099).
- O LightGBM foi o melhor modelo para classificação; o Random Forest para regressão.

Recomendação prática: em cenários com restrição computacional, o SimpleImputer com mean ou median é uma escolha robusta e eficiente. Métodos mais sofisticados como KNN e IterativeImputer trazem ganhos marginais em datasets com alta correlação entre variáveis. O miceforest requer configuração mais cuidadosa (mais iterações e colunas) para superar métodos simples.

Uso de Inteligência Artificial

Este trabalho utilizou o Claude (Anthropic) como auxílio na depuração do código Python, otimização do pipeline de execução paralela, e na estrutura do relatório.